



**PROYECTO ETL: PRIMERA ENTREGA**

**JHEFFREY URBANO GARCES  
ALEXANDER MOSQUERA FAJARDO**

**ETL  
M.Sc. DANIEL FELIPE ROMERO BERNAL**

**UNIVERSIDAD AUTÓNOMA DE OCCIDENTE  
FACULTAD DE INGENIERÍA Y CIENCIAS BÁSICAS  
INGENIERÍA DE DATOS E INTELIGENCIA ARTIFICIAL  
SANTIAGO DE CALI  
2026**

|                                                              |   |
|--------------------------------------------------------------|---|
| 1. Introducción y Propósito del Proyecto                     | 3 |
| 2. Evaluación y Selección de la Fuente de Datos              | 3 |
| 3. Arquitectura del Proyecto y Stack Tecnológico             | 3 |
| 4. Retos en el Procesamiento y Transformación de Datos (ETL) | 4 |
| 5. Diseño del Modelo de Datos: Esquema Estrella              | 4 |
| 6. Resultados del Análisis Exploratorio de Datos (EDA)       | 5 |

#### **GitHub Repositorio**

[https://github.com/JheffreyUrbano/proyecto\\_etl\\_ods](https://github.com/JheffreyUrbano/proyecto_etl_ods)

#### **Fuente de los datos**

[https://www.datos.gov.co/Justicia-y-Derecho/Presuntos-Suicidios-Colombia-2015-a-2024-Cifras-de/f75u-mirk/about\\_data](https://www.datos.gov.co/Justicia-y-Derecho/Presuntos-Suicidios-Colombia-2015-a-2024-Cifras-de/f75u-mirk/about_data)

## 1. Introducción y Propósito del Proyecto

Desarrollamos este proyecto con el objetivo de construir un proceso completo de Extracción, Transformación y Carga (ETL) que nos permitiera organizar, depurar y analizar los registros de presuntos suicidios ocurridos en Colombia entre 2015 y 2024.

Desde la fase de ideación, decidimos que nuestro análisis debía tener un propósito social claro. Por ello, articulamos nuestro trabajo con el **Objetivo de Desarrollo Sostenible (ODS) 3: Salud y Bienestar**. A través de la ingeniería de datos, buscamos transformar registros crudos en una base de datos perfilada que permita identificar grupos demográficos y territorios vulnerables. Entendemos que nuestro rol no es emitir diagnósticos médicos o judiciales, sino construir una infraestructura de datos confiable que sirva como punto de partida para que los expertos en salud pública estructuren estrategias de prevención.

## 2. Evaluación y Selección de la Fuente de Datos


Para cumplir con los requisitos académicos del curso (mínimo 10.000 filas y 10 características), realizamos una búsqueda exhaustiva hasta seleccionar el dataset oficial del Instituto Nacional de Medicina Legal y Ciencias Forenses, disponible en el portal de Datos Abiertos de Colombia.

Nuestra justificación para elegir esta fuente se basa en tres pilares:

1. **Volumen y Riqueza:** El dataset cuenta con 26.558 registros y 32 variables detalladas (temporales, geográficas, sociodemográficas y circunstanciales), lo que nos brindó un terreno ideal para aplicar técnicas de transformación en clase y aprender tanto nuevas técnicas como nuevos problemas.
2. **Impacto Social:** Es una base de datos real y de alto interés nacional que nos exige un tratamiento ético y riguroso de la información.
3. **Calidad Inicial:** Al explorar los datos, notamos que contenían errores de captura, nulos enmascarados y duplicidades semánticas; el escenario perfecto para demostrar nuestras habilidades en la limpieza y estructuración de datos.

## 3. Arquitectura del Proyecto y Stack Tecnológico

Para garantizar que nuestro pipeline fuera reproducible y escalable, diseñamos una arquitectura estructurada en capas:



Como equipo, tomamos decisiones específicas sobre las herramientas a utilizar:

- **Python y Pandas:** Elegimos Pandas como nuestro motor de procesamiento en memoria por su altísima eficiencia para realizar transformaciones vectorizadas, limpiezas con expresiones regulares y cruces de datos antes de la carga.
- **PostgreSQL:** Seleccionamos este motor relacional por su robustez en el manejo de esquemas analíticos y su estricto control de llaves primarias y foráneas, garantizando la integridad de nuestro Data Warehouse.
- **dbdiagram.io:** Utilizamos esta herramienta para modelar visualmente nuestro esquema estrella y autogenerar el código DDL, lo que nos permitió trabajar de manera colaborativa.
- **Control de Versiones (Git/GitHub):** Mantuvimos un repositorio organizado separando los entornos de trabajo: un Jupyter Notebook para la ingeniería de datos (01\_etl\_pipeline.ipynb) y otro exclusivamente para el análisis (02\_etl\_edu.ipynb).

#### 4. Retos en el Procesamiento y Transformación de Datos (ETL)

La fase de transformación fue el mayor reto del proyecto. No nos limitamos a borrar valores nulos, sino que aplicamos métodos avanzados para rescatar la mayor cantidad de información posible:

- **Problemas de Codificación y Texto:** Nos enfrentamos a errores de *Mojibake* (caracteres corruptos), los cuales solucionamos forzando la lectura en UTF-8 y estandarizando todos los textos (conversión a mayúsculas, eliminación de espacios invisibles y uso de librerías Unicode para remover tildes).
- **Homologación Inteligente:** Descubrimos que muchas variables categóricas estaban fragmentadas por errores tipográficos (ej. variaciones de "Menor de edad"). Implementamos un algoritmo propio utilizando SequenceMatcher para detectar similitudes entre cadenas de texto, automatizando la agrupación de categorías equivalentes. Además, unificamos manualmente los niveles educativos (ej. preescolar, posgrado) para facilitar el análisis.
- **Tratamiento Ético de Nulos:** Identificamos que variables sensibles como *Orientación Sexual* o *Pertenencia Étnica* tenían valores etiquetados como "Sin Información". Decidimos no eliminarlos ni imputarlos matemáticamente para no sesgar a poblaciones vulnerables (clave para el ODS 3); en su lugar, estandarizamos estos valores bajo la etiqueta NO REGISTRA, permitiéndonos auditar la calidad del dato institucional.
- **Consistencia Relacional:** Convertimos los identificadores y códigos DANE al tipo Int64 nativo de Pandas y eliminamos los registros duplicados, asegurando que los datos estuvieran listos para el modelado dimensional.

#### 5. Diseño del Modelo de Datos: Esquema Estrella

Para la etapa de carga, decidimos abandonar el modelo plano del CSV original e implementar un esquema estrella basado en la metodología de modelado dimensional. Esta decisión técnica optimiza la velocidad de las consultas de agregación en la fase de análisis.

[Insertar imagen del diagrama entidad-relación generado en dbdiagram.io]

Nuestra base de datos quedó estructurada de la siguiente manera:


- **Tabla de Hechos (fact\_presuntos\_suicidios):** Centraliza las métricas. Cada fila representa un evento único, enlazado mediante llaves foráneas a su contexto.
- **Dimensiones Analíticas:**
  - dim\_tiempo: Nos permite segmentar tendencias por año, mes, día y rango horario.
  - dim\_geografia: Desacopla la ubicación, permitiendo cruces a nivel de localidad, municipio y departamento.
  - dim\_victima: Agrupa todo el perfil demográfico y social (edad, sexo, estado civil, escolaridad).
  - dim\_circunstancia: Clasifica los detalles del incidente (escenario, mecanismo causal, razones reportadas).

## 6. Resultados del Análisis Exploratorio de Datos (EDA)

Para cumplir con las exigencias de la rúbrica, garantizamos que todas las visualizaciones se alimentaran exclusivamente mediante consultas SQL hacia PostgreSQL, confirmando el éxito de nuestra migración de datos.

Durante el análisis, extrajimos *insights* descriptivos clave para el ODS 3:


1. **Estacionalidad y Patrones Temporales:** Analizamos la evolución histórica de casos (2015-2024), detectando qué meses y franjas horarias concentran un mayor número de incidentes.



Total histórico de casos registrados: 26.558

La serie muestra la evolución anual de presuntos suicidios en Colombia entre 2015 y 2024. El total histórico registrado es de 26,558. El año con mayor número de registros fue 2023 con 3,195 casos, mientras que el menor fue 2015 con 2,068 casos.


La media anual fue de 2,656 casos. Se observa un crecimiento general desde 2015 hasta 2023, con una caída leve en 2020 y un descenso adicional en 2024. Esto sugiere que la carga de registros ha aumentado en el tiempo, pero no permite afirmar un aumento real de la incidencia sin considerar mejoras en la notificación, cambios en la calidad de la información o variaciones en la población y el acceso a la atención. El gráfico refleja la evolución de los registros, no necesariamente la tasa de suicidio real por lo que se toma solamente como descriptivo.




Los casos se concentran principalmente los DOMINGO y en el rango 09:00 A 11:59. La combinación con mayor frecuencia fue DOMINGO entre 15:00 A 17:59. La información sin día u hora fue excluida para evitar que domine la escala de colores.

La mayor concentración se observa en los días DOMINGO (1527), LUNES (1292), SABADO (1145) y en los rangos horarios 09:00 A 11:59 (1198), 15:00 A 17:59 (1186), 12:00 A 14:59 (1143). Esto sugiere un patrón temporal con mayor aglomeración en fines de semana y en franjas de actividad diurna, pero no permite concluir causalidad ni riesgo real sin ajustar por población, calendario y calidad de la información.

2. **Identificación de Población Vulnerable:** Al cruzar la dimensión víctima con las circunstancias del hecho, comparamos cómo varían los mecanismos causales elegidos según el sexo y el ciclo vital (adolescencia, adultez, adulto mayor).




En esta gráfica se agrupan los casos por ciclo vital y se observa que la mayor concentración corresponde a la juventud y la adultez, mientras que la adolescencia y la infancia muestran frecuencias mucho menores. Esto indica que los registros se concentran principalmente en etapas adultas, pero no permite afirmar diferencias de riesgo por población ni establecer causalidad, porque la visualización representa cantidades absolutas y no tasas ajustadas por población o estructura demográfica. La comparación es descriptiva y ayuda a identificar dónde está más concentrada la carga de casos en la muestra.




En esta gráfica se comparan los casos de suicidio por sexo y mecanismo causal de la

lesión fatal. Se observa que, en ambos sexos, los mecanismos más frecuentes son los generadores de asfixia y el uso de tóxicos, aunque los hombres concentran una mayor proporción en casi todas las categorías. Esta visualización ayuda a identificar patrones diferenciales por sexo y a describir la distribución de los mecanismos más usados, pero no permite afirmar causalidad ni comparar tasas ajustadas por población.


3. **Factores de Contexto:** Observamos la distribución de casos según el nivel de escolaridad y las razones reportadas (ej. conflictos de pareja, dificultades económicas), segmentándolos entre cascos urbanos y zonas rurales.



La combinación más frecuente fue 'SIN INFORMACION' en el estado civil 'SOLTERO(A)', con 7000 registros. Este resultado describe lo que aparece reportado en la fuente y no prueba que sea la causa del hecho. Es bastante preocupante la razón de Conflicto con pareja o Ex-pareja, Desamor así como las económicas o las enfermedades mentales y/o adicción, siendo estas las principales a acatar en medidas preventivas.




El departamento con más registros es ANTIOQUIA y la zona con mayor cantidad de casos es CABECERA MUNICIPAL. Este resultado representa volúmenes absolutos; no permite comparar riesgo territorial sin datos de población. Importante mencionar que Antioquia tiene basto territorio rural.



El nivel educativo con más registros es 'BASICA PRIMARIA', con 7030 casos. Esta distribución puede estar relacionada con la composición de la población registrada y no permite concluir que un nivel educativo proteja o cause un mayor riesgo.

4. **Auditoría de Calidad:** Gracias a nuestro manejo de nulos, pudimos graficar las brechas de información en las variables de identidad de género, demostrando que existe una gran oportunidad de mejora en la recolección de datos desde las instituciones forenses.



La variable con más registros sin información es 'identidad\_genero', con 17397 casos. Esto muestra una limitación importante del conjunto y recomienda interpretar con cuidado las comparaciones entre poblaciones. Esta es una oportunidad de mejora que podría hacer preciso un análisis de hechos frente a un contexto y variables sensibles para analizar lo positiva o negativa que ha sido la influencia de campañas de cercanía a personas con sexualidad diversa.

## 7. Conclusión del Proyecto

Como equipo, este proyecto nos permitió consolidar conocimientos técnicos en extracción, limpieza y modelado en un entorno SQL. Más allá del código, aprendimos la importancia de la calidad del dato: un Data Warehouse estructurado y éticamente depurado es una herramienta poderosa que transforma registros aislados en conocimiento útil para la formulación de políticas públicas en salud mental.